Préparé par
Dr R.BOUSMAHA

Fiche TP N° 01 : LE PRETRAITEMENT EN NLP

Objectif :

✈ Connaitre les notions de base des prétraitements en NLP

Librairies nécessaires

Nltk

SpaCy

WordCloud

Pywaffle

pyspellchecker

unidecode

textblob etc…

A. Préparation de données

1. Importer le jeu de données **spooky.csv** à partir de l'URL https://github.com/GU4243-ADS/spring2018-project1-ginnyqg/raw/master/data/spooky.csv en utilisant pandas et afficher les **10** premiers échantillons.

B. Nettoyage d'un texte

1. Gérer les caractères répétitifs (par exemple « coooooool » → « cool »)
2. Manipuler des homoglyphes (par exemple « $tupide » → « stupide »)
3. Transformer les entrées spéciales telles que les URL, les adresses e-mail et les balises HTML à une forme canonique.
4. Mettre tous les caractères en minuscule.
5. Supprimer la ponctuation
6. Supprimer les mots-vide + mots < 3 chars.
7. Correction orthographique (pyspellchecker)

C. Segmentation

1. Segmenter chaque phrase sur les espaces / la ponctuation
2. Segmenter chaque phrase avec un algorithme de segmentation basé sur des règles
3. Segmenter chaque phrase avec un algorithme de segmentation en sous mots (Subword Tokenization)

D. Reconnaissance d'entité nommée

Avec SpaCy/NLTK :

1. Extraire PERSON, ORG, GPE, DATE sur 50 phrases
2. Compter fréquences entités/auteur
3. Visualiser top-10 entités globales

E. Réduction des formes

1. Avec NLTK utiliser la lemmatisation et la racinisation.
2. Comparer 3 approches sur 100 phrases : NLTK Stem, NLTK Lemmatize et SpaCy Lemmatize.

F. Analyse des fréquences

1. Compter le nombre de phrases, pour chaque auteur, où apparaît le mot **Great**.

Utiliser **pywaffle** pour obtenir un graphique qui résume de manière synthétique le nombre d'occurrences du mot " **great** " par auteur.

2. Refaire l'analyse avec le mot "**impossible**".

3. En utilisant la fonction **wordCloud**, faire trois nuages de mots pour représenter les mots les plus utilisés par chaque auteur.
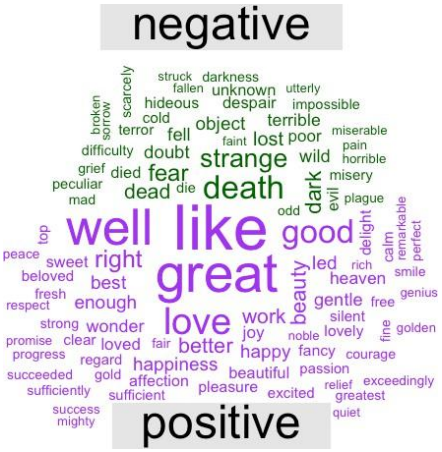
4. En utilisant la fonction **wordCloud**, montrer les 100 meilleurs mots positifs et négatifs utilisés par les auteurs.